

Tarea final: un agente para su proyecto

Objetivo: construir un agente con lo aprendido durante el curso

Elijan un problema propio o laboral para construir un agente. Antes de implementarlo, delimiten qué resolverá y definan cómo reconocerán un resultado correcto. Luego desarrollen las funciones y herramientas necesarias para ese caso. Cumplan la base obligatoria y agreguen solo las ampliaciones que aporten a su solución: no tienen que usar todas las técnicas del curso. El agente debe funcionar y otra persona debe poder ejecutarlo y revisarlo.

Base obligatoria para optar al 4,0

0,5

Caso y criterio de éxito

Usuario, entrada, alcance, salida esperada y una comprobación observable. El caso justifica el uso de un LLM y una herramienta.

0,5

LLM real y trazabilidad

Llamada ejecutada por API o con modelo local. Identifiquen modelo, configuración, fuentes y prompts de las llamadas al LLM; dejen una traza legible.

1,0

ReAct integrado

El LLM solicita una herramienta básica pertinente; su observación vuelve al LLM. Hay decisión de repetir o responder y una condición de parada explícita.

0,5

Historial simple

Reenvíen mensajes al LLM. En un segundo turno debe usar un dato dado en el primero, como el nombre, sin una respuesta fijada en código.

0,5

Seguridad básica

Instrucciones de alcance y acciones permitidas en cada llamada al LLM que pueda decidir o responder. Ante una petición fuera de alcance o un jailbreak sencillo, debe respetar los límites y no ejecutar acciones prohibidas. Corrijan y repitan si se rompe.

Escala: 1,0 inicial + hasta 3,0 de estos cinco criterios = **4,0**. Las ampliaciones elegidas pueden añadir hasta **3,0** para llegar a **7,0**. El notebook, el entorno, los prompts y las pruebas son evidencia de los criterios, no un sexto rubro.

Elijan sus ampliaciones

Capacidades opcionales para avanzar del 4,0 al 7,0

Elijan solo las que aporten a su problema. Pueden combinar categorías; **no deben hacerlas todas**. Cada bono exige una prueba ejecutada y reproducible. La suma de bonos tiene tope **+3,0**.

+1,0 por capacidad

Memoria avanzada

+1,0

Resumen o estado útil más allá del historial bruto.

Prueba: Estado inicial, actualización y uso posterior en una respuesta o decisión. Persistencia opcional.

No suma si: solo reenvía mensajes o guarda algo que nunca usa.

Workflow adicional

+1,0

Ejemplos: router que elige ruta, planificador que ordena pasos o refinamiento iterativo que evalúa y mejora respuestas.

Prueba: Trazas de ruta seleccionada, plan adaptado o respuesta revisada; muestren su efecto.

No suma si: solo hay un diagrama o no se ejecuta la ruta, el plan o la revisión.

RAG

+1,0

Recuperen documentos con el Redis del curso cuando la respuesta necesite el corpus. No se admite un índice local alternativo.

Prueba: Entrada y decisión de recuperar; corpus, índice exacto, carga y configuración (embeddings, campos, dimensiones, métrica y algoritmo). Fragmentos, fuentes y uso en la respuesta.

No suma si: no usa Redis del curso, no recupera o lo invoca sin necesidad.

MCP

+1,0

Servidor libre y gratuito, invocado solo si el agente necesita su herramienta o recurso.

Prueba: Entrada, decisión, descubrimiento y llamada real. Nombre/versión, host/URL o comando, instalación y datos de prueba. Claves: obtención gratuita y variables, sin secretos.

No suma si: solo está configurado, se llama para toda entrada o depende de acceso privado o pago inaccesible.

+0,5 por capacidad

Herramienta avanzada de edición o acción

+0,5

Acción autorizada distinta de la consulta básica.

Prueba: Llamada y estado anterior/posterior en un entorno controlado.

No suma si: es otra lectura o no puede repetirse con seguridad.

Evaluación con golden set

+0,5

Casos con expectativa y criterio explícitos.

Prueba: Golden set versionado, completo y ejecutado: entradas, expectativas, veredictos y resultados por caso. Corrijan los casos fallidos y vuelvan a ejecutar; la corrida final debe cumplir los criterios.

No suma si: faltan ejecuciones, quedan fallos sin resolver o eliminan casos fallidos para ocultarlos.

Guardrail avanzado o juez

+0,5 c/u

Control independiente por encima de la seguridad basal.

Prueba: Caso benigno y adversarial, veredicto y decisión aplicada. Si hay juez LLM: modelo, prompt y veredictos.

No suma si: duplica el prompt basal, no aplica el veredicto o repite otro control.

Regla común

Declaren los bonos que solicitan y dónde se ejecutan. No hay doble crédito por el mismo mecanismo; otra API o el nombre de una tecnología no suman por sí solos.

Cuándo usar RAG o MCP

"Hola": respuesta directa, sin RAG ni MCP. **Pregunta sobre el corpus:** RAG con Redis del curso. **Tarea que necesita una herramienta del servidor:** MCP. Muestren entradas con y sin necesidad de uso, decisión del agente y llamada solo cuando corresponda.

Construcción y entrega

Un notebook Jupyter .ipynb ejecutable, con instrucciones para repetirlo

Secuencia de trabajo

- 1 Delimiten el caso.** Escriban usuario, entrada, salida, límites y una prueba de éxito observable.
- 2 Preparen el entorno.** Declaren versión de Python, dependencias y acceso al LLM. No incluyan credenciales reales.
- 3 Seleccionen información y herramientas.** Usen datos autorizados y una herramienta básica útil para el caso.
- 4 Dejen visibles las instrucciones.** Documenten prompts, roles y parámetros de cada llamada al LLM del agente. Si usaron OpenCode para desarrollar el proyecto, adjunten también los prompts o instrucciones que le dieron: nos ayudarán a orientarlos y sugerir mejoras. No incluyan claves ni datos privados.
- 5 Implementen el ciclo ReAct.** Muestren llamada a herramienta, observación devuelta al LLM, nueva decisión y parada.
- 6 Conserven el historial.** Reenvíen los mensajes y demuestren el segundo turno. Luego integren las ampliaciones que eligieron.

Ficha mínima para reproducirlo

Modelo	Proveedor o runtime, identificador exacto, versión y parámetros relevantes; si es local, cómo obtenerlo.
Dependencias	requirements.txt, environment.yml o equivalente, con versiones e instalación.
Variables	Nombres y función de las variables de entorno, sin valores secretos. La persona revisora configurará sus propias credenciales si usa una API.
Datos	Origen, versión y modo de obtener o reconstruir los datos y ejemplos de prueba autorizados.

Entrega mínima: .ipynb, especificación del entorno, datos o receta de obtención, prompts del agente y trazas de ejecución. Si usaron OpenCode, adjunten por separado los prompts de desarrollo. Si declaran ampliaciones, sumen los archivos y configuraciones necesarios para probarlas.

Pruebas y revisión

Cada caso debe mostrar entrada, ejecución observada y resultado

Pruebas y verificación antes de entregar

Caso normal	Entrada válida, herramienta llamada, observación que regresa al LLM, decisión final y parada.
Segundo turno	Un dato anterior, por ejemplo el nombre, se usa desde el historial enviado al LLM; una respuesta fija no cuenta.
Seguridad básica	Petición fuera de alcance y jailbreak sencillo: respeta los límites, responde de forma segura y no ejecuta acciones prohibidas. Si se rompe, corríjanlo y repitan la prueba.
Verificación final	Todas las pruebas y evaluaciones declaradas deben estar completas y cumplir sus criterios. Si apareció un fallo al desarrollar o probar, arréglenlo y vuelvan a ejecutar antes de entregar. No se pide provocar un fallo.

Cómo revisará el docente

La persona revisora instalará el entorno, preparará los datos y ejecutará el notebook desde cero y en orden. Verificará la traza del LLM, la herramienta, el historial y la condición de salida. Después repetirá solo las ampliaciones declaradas y contrastará sus evidencias con lo ejecutado.

Consecuencias en la nota

Flujo central	Si en la revisión sigue sin funcionar LLM, ReAct, herramienta, devolución de observación, parada o historial, la nota final tiene tope 3,0 . Un error anterior corregido y verificado no activa este tope.
Seguridad basal	Si en la revisión una petición fuera de alcance o un jailbreak sencillo rompe los límites, pierde sus 0,5 ; no impone por sí solo otro tope 3,0.
Bonos	Una ampliación fallida no suma, pero no quita una base que funciona. Los bonos tienen tope +3,0 y no se acredita dos veces el mismo mecanismo.

No publiquen claves, datos personales ni recursos privados. Para acciones externas, utilicen recursos de prueba que otra persona pueda usar con seguridad.